

지진 예측을 위한 머신러닝 기법 설계



201824584 정지호
201724606 최지환
201724442 김주은

지도교수 송길태

목 차

1. 서론	1
1.1 연구 배경	1
1.2 기존 문제점	1
1.3 연구 목표	1
2. 연구 배경	2
2.1 배경지식	2
2.1.1 CNN	2
2.1.2 LSTM	2
2.1.3 Bi-LSTM	3
2.1.4 GRU	3
2.1.5 Confusion Matrix	3
2.2 요구조건	4
2.3 기존 제약사항 및 극복	5
2.3.1 제공된 Dataset과 실행환경에 따른 한계	5
2.3.2 실시간 데이터의 부재	6
3. 연구 내용	7
3.1 모델설계	7
3.2 실시간 예측 기능	8
4. 연구 결과 분석 및 평가	10
4.1 모델 학습 결과	10
4.1.1 파라미터	10
4.1.2 추론속도	11

4.1.3 모델 크기	12
4.1.4 F1 Score	12
4.1.5 False Negative	14
4.1.6 최종 모델 제시	14
5. 결론 및 향후 연구 방향	16
6. 개발 일정 및 역할 분담	17
7. 참고 문헌	18

1. 서론

1.1 연구 배경

최근 딥러닝은 우리 사회의 다양한 응용분야에 적용되고 있고 이의 중요성이 더욱 주목받고 있다. 기상과 자연재해 등 예측 불가능하던 상황을 예측할 수 있고, 그에 따라 미리 대응하여 피해를 줄일 수 있다는 점에서 해당 분야에서는 점점 더 중요성이 커지고 있다. 특히 본 연구에서는 지진에 대해 다룰 것이다. 최근 지진으로 인한 피해가 많이 발생하는 만큼, 지진 예측에 있어서 높은 정확도와 예측 속도가 빠른 모델의 개발이 필요하다고 생각했다.

1.2 기존 문제점

기존에 개발된 지진 예측 딥러닝 모델인 EQTransformer(이하 EQT)는 지진 신호를 추출하여 학습하고 이를 예측하는데 있어서 높은 정확도를 보인다.

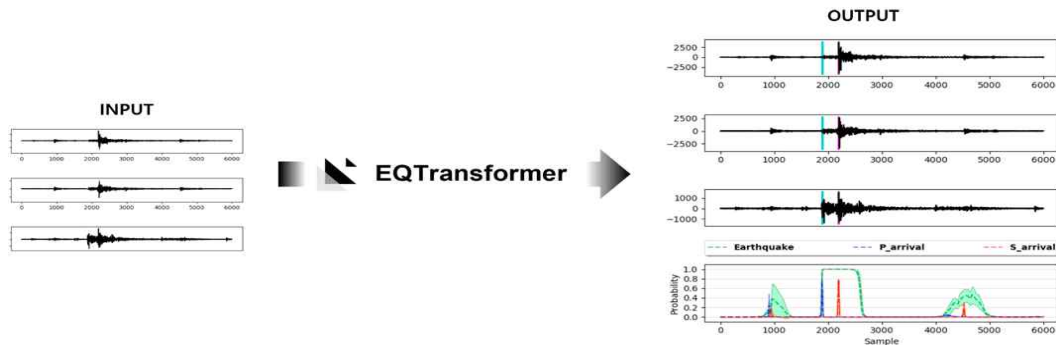


그림 1) EQTransformer의 실행 예시

하지만 그에 반해 예측 소요 시간이 꽤 길기 때문에 실시간으로 사용할 수 없다. 또한 모델의 사이즈가 너무 커서 상용화하기에 현실적으로 불가능하다는 문제를 가지고 있다.

1.3 연구 목표

지진은 빠른 초기 대응이 피해 최소화에서 가장 중요하다. 때문에 지진 감지에 있어서는 초단위의 시간도 큰 의미가 있다고 생각하며, 짧은 예측 시간이 필요하다. 따라서 실질적으로 사용할 수 있는 빠른 모델의 개발이 필요하다고 생각했다. 중간 보고서에서 언급한 바와 같이 효과적인 모델 개발을 위해 EQT를 개선시킨 LEQNet(이하 LEQ) 모델을 참고하였다. 즉 본 연구는 EQT와 LEQ를 기반으로 적은 시간이 소요되는 지진 예측 딥러닝 모델을 개발하는 것을 목표로 했다. 또한 기존 목표에서 추가하여, 실시간 처리를 구현하고자 한다.

최종 목표는 속도 개선과 경량화와 더불어, 실시간 예측 또한 적용된 상용화 가능한 모델을 개발하는 것이다. 우리의 개발 모델은 FEQTrasnformer(이하 FEQ)라 한다.

2. 연구 배경

2.1 배경 지식

2.1.1 CNN(Convolutional Neural Network)

CNN은 인간의 시신경을 모방하여 만든 딥러닝 구조 중 하나이다. Convolution 연산을 이용하여 연산량을 크게 줄일 수 있다는 장점을 갖고 있다. 본 연구에서는 데이터의 특징을 학습하는 역할을 한다.

- ResNet

ResNet은 CNN의 모델 중 대표적인 모델이다. 깊은 망을 더 쉽게 학습할 수 있도록 개발된 네트워크로, 네트워크의 깊이를 늘리면서도 안정적인 학습이 가능하다. EQT에서 사용되었다.

- Bottleneck

Bottleneck은 병목 구조라고도 하며, Convolution 전, 후에 kernel size가 1인 kernel을 이용하여 채널 수를 감소시켰다가 convolution 이후에 다시 채널 수를 복구하는 기법으로, LEQ에서 사용되었다.

2.1.2 LSTM(Long Short Term Memory)

LSTM은 RNN의 소멸, 폭주 문제를 해결하는 대표적인 개선 방안 구조이다. LSTM은 입출력 및 망각을 제어하는 게이트를 추가하여 그때그때 새로 계산되는 값들을 연산에 사용한다는 점을 특징으로 갖는다. LSTM 셀의 구조는 아래와 같다.

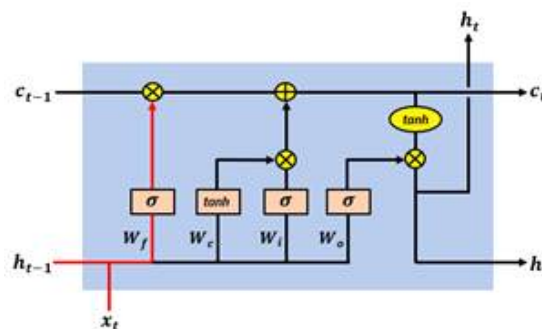


그림 2) LSTM구조

2.1.3 Bi-LSTM (Bidirectional LSTM)

Bi-LSTM은 양방향 LSTM 또는 두 개의 LSTM으로 구성된 시퀀스 처리 모델이다. 게이트 기법을 통해 RNN의 한계를 극복한 모델인 LSTM을 역방향의 결과를 함께 이용한다. 하나의 입력은 순방향으로, 다른 하나는 역방향으로 사용한다. 이 모듈은 네트워크에서 사용할 수 있는 정보의 양을 효과적으로 증가시켜 알고리즘에서 사용할 수 있는 컨텍스트를 개선한다.




그림 3) Bi-LSTM 구조

2.1.4 GRU

LSTM에서는 출력, 입력, 망각을 담당하는 3개의 게이트가 존재한다. 반면, GRU에서는 업데이트 게이트와 리셋 게이트 총 두 가지 게이트만이 존재한다. GRU와 LSTM 중 어떤 것이 모델의 성능 면에서 더 낫다고 단정 지어 말할 수 없다. 매개변수가 적으면 GRU가 일반적으로 LSTM보다 훈련하기 쉽고 빠르다고 알려져 있다. FEQ에서 사용되었다.

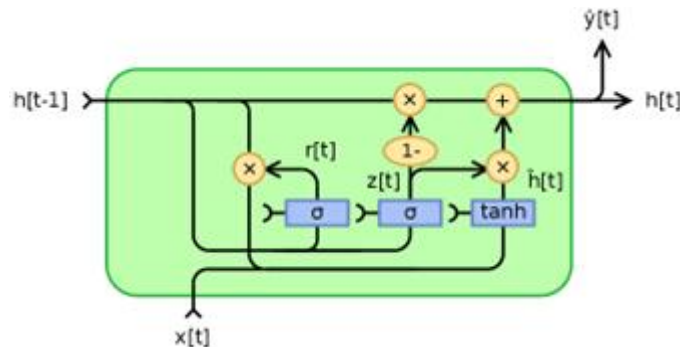


그림 4) GRU 구조

2.1.5 Confusion Matrix

Confusion Matrix는 일반적으로 이진 분류 문제에서 평가 지표로 사용된다. 실제 지진파가 지진으로 감지되면 TP, 감지되지 않으면 FN이다. 노이즈 데이터는 노이즈로 예측될 때 TN, 지진으로 예측될 때 FP이다. P파와 S파의 실제 도착 시간과 모델의 시간이 0.5초 이내일 때 TP로 계산한다. Precision과 Recall의 조화평균을 나타내는 F1 Score의 계산법은 다음과 같다.

$$F1\ Score = 2 \times \frac{precision \times recall}{precision + recall}$$

2.2 요구조건




그림 5) EQT 모델 구조




그림 6) LEQ 모델 구조

그림 5는 EQT 모델의 네트워크 구조이고, 그림 6은 EQT를 개선한 모델인 LEQ의 모델 구조이다.

LEQ는 EQT에서 CNN을 용도에 따라 분리하고 ResNet 구조를 병목 구조 방식을 적용하여 성능을 더 향상시키고 경량화가 진행된 모델이다.

하지만 매개변수의 수를 줄이면 성능의 저하가 있고 EQT와 마찬가지로 여전히 소형 장치에 적합하지는 않다. 따라서 본 연구에서는 EQT와 LEQ, 두 모델을 모두 참고하여 활용성 면에서 더 뛰어나며 성능의 저하가 적은 모델을 개발할 것이다. 이를 위해 파라미터 수를 줄이고 추론 속도를 향상시켰다. LEQ를 참고해 보았을 때, Encoder와 Decoder, ResNet에서 큰 경량화가 있었지만, LSTM과 Transformer에서는 기존 모델인 EQT와 큰 차이가 없었으므로 해당 부분을 수정하고자 하였다.

2.3 기존 제약 사항 및 극복

2.3.1 제공된 Dataset과 실행 환경에 따른 한계

기존의 EQT 모델은 STEAD Dataset을 사용했다. 이 데이터는 일본을 제외한 지진활동 국가의 지진 신호를 포함한 것이다. EQT는 해당 dataset을 모델에 학습시킨 후, 일본의 지진 데이터를 예측하는 데에 높은 성능을 보였다. 그러나 본 연구에서 이와 같은 STEAD Dataset을 모두 사용해 모델링을 진행하기에는 해당 데이터의 양이 너무 방대하여 성능 테스트에서 사용했던 것과 같이 추출된 일부의 dataset을 사용할 예정이었다.

또한, 기존 모델을 개선해 실행 속도를 줄이는 것이 해당 연구의 목표였다. 속도, 즉 예측시간은 개인의 실행 환경에 따라 달라진다. 특히 학습이 일반적인 노트북으로 진행된다는 점에서 전반적인 속도가 느려질 수 있으며, 예측 소요 시간으로 해당 환경에서 실행 속도를 정확하게 측정하기는 어렵다. 이러한 한계는 절대적인 속도보다는 개선 전후의 상대적인 비교를 함으로써 해결하고자 하고, 개선 전과 후의 연산량과 파라미터 수의 비교를 통해 속도 개선을 확인해 볼 예정이었다.

우리는 지도교수님께 서버를 지원받아 이러한 한계를 극복할 수 있었다. FEQ 모델은 빠른 속도의 서버로 학습 속도가 크게 감소했고, 그로 인해 기존보다 많은 양의 data를 학습시킬 수 있었다. 결과적으로 STEAD 데이터의 약 40%(120만개 중 50만개)인 Dataset을 학습에 사용하여, 보다 정확한 결과를 얻을 수 있었다.

2.3.2 실시간 데이터의 부재

해당 연구의 최종 목적은 기존 모델의 추론 속도를 개선해 상품으로써의 활용성을 향상시키는 것이었다. 우리가 제시한 모델을 실시간 지진 예측에 활용하여 응용 가능한 방식을 제시해 보고자 한다. 하지만, 실시간으로 지진 데이터를 입력받아, 지진 발생 여부를 예측하는 것은 적절한 데이터가 없어 불가능하다는 한계가 있었다. 또한, 실시간 지진 데이터를 입력받는다 하더라도, 지진이 발생하지 않는 한, 해당 모델이 실제로 지진을 예측하는지 검증할 수 없다. 따라서 해당 기능을 구현하기 위해, 기존의 STEAD 데이터에 포함된 데이터를 활용하여 연속적인 지진 데이터를 임의로 만들었다. STEAD 내 포함된 노이즈 데이터의 발생 시간을 수정하여 지진 데이터 이전에 연속적으로 발생하도록 바꾸었다. 즉 3분의 연속적인 노이즈 데이터 이후 지진이 발생하는 데이터를 사용해 모델이 지진을 실시간으로 예측하는 것처럼 보이게 했다.

3. 연구 내용

3.1 모델 설계

LEQ와 EQT 모델에서 사용한 RNN 모듈은 LSTM이다. FEQ는 이 LSTM을 GRU로 변경하여 파라미터 수를 감소시켰다. 2.1절에서 설명했듯, GRU는 LSTM의 구조를 조금 더 간단하게 개선한 것으로 LSTM과 비슷한 성능을 보인다. 하지만 GRU는 더 적은 게이트 수 덕분에 LSTM과 비교했을 때 학습할 파라미터 수가 더 적다는 것이 장점이다. 또한 FEQ에서는 CNN(Deeper Bottleneck 구조, EQT의 ResNet에 해당), GRU 블록의 수를 감소시켰다. 계층의 깊이가 깊어질수록 파라미터 수가 많아져, 모델의 경량화가 어려워지기 때문이다.

본 연구에서는 여러 가지 RNN 모듈을 사용해보고, 블록의 깊이와 Threshold 값 등 여러 조건을 변경하며 최적의 모델 조건을 찾아내고자 했다. 아래 그림 7~9는 사용한 RNN 모듈에 따른 각 FEQ의 구조도이다.

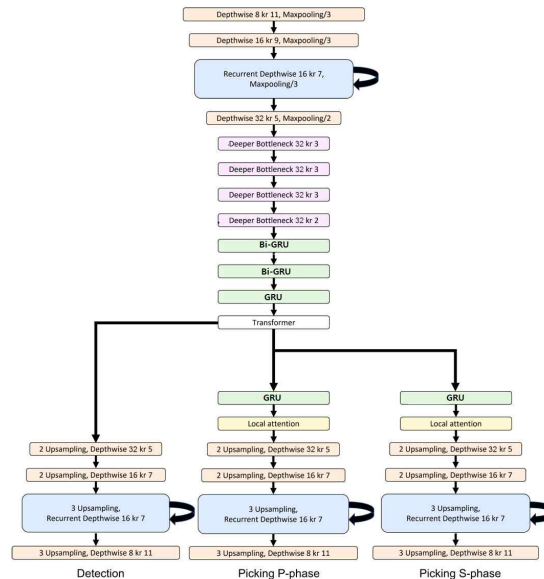


그림 7) Bi-GRU, GRU 사용 모델 구조(FEQ1)

그림 7은 LEQ 모델에서 Bi-LSTM을 Bi-GRU로, LSTM을 GRU로 변경한 모델 (이하 FEQ1)이다. 데이터를 학습시킨 결과 기존 모델들보다 모델 크기와 파라미터 수가 감소하긴 했으나 근소한 차이였고, 추론 속도 면에서 개선이 아주 미세했다. 따라서 우리는 다른 시도를 해보았다.

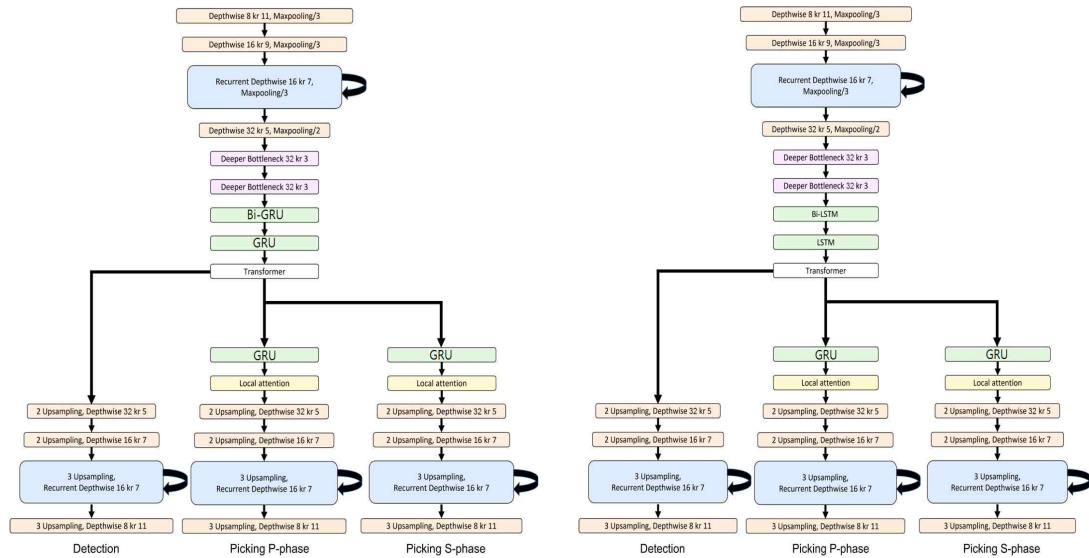


그림 8) Bi-GRU, GRU 사용 모델 구조(FEQ2)

그림 9) Bi-LSTM, GRU 사용 모델 구조(FEQ3)

그림 8은 CNN 블록 수를 2로 감소시키고, Bi-GRU와 GRU를 적용시킨 FEQ2 모델(이하 FEQ2)이다. 그림 9는 FEQ2과 같은 블록 수를 사용하였으나 Bi-LSTM, GRU를 적용시킨 모델(이하 FEQ3)이다. 우리는 본 연구에서 여러 시도를 해보았으나, 최종적으로 비교할 모델들은 이 세 가지로 나누어볼 수 있다.

3.2 실시간 예측 기능

해당 연구의 최종 목적은 기존 모델의 추론 속도를 개선해 상품으로써 활용성을 향상시키는 것이었다. 우리가 제시한 모델을 실시간 지진 예측에 활용하여 응용 가능한 방식을 제시해 보고자 한다. 본 연구에서 최종적으로 제시하는 모델은 Bi-LSTM과 GRU를 사용한 FEQ3이다. 앞서 언급한 것처럼, 실시간으로 데이터를 사용할 수 없으므로 기존의 데이터를 수정하여 연속적인 데이터처럼 보이게 하였다.

1분 단위의 다른 노이즈 데이터를 입력받아 그래프에 각자 다른 색으로 나타내었다. 각 데이터를 입력받을 때마다 모델이 이들이 지진 데이터인지 감지하고, 지진이 아니라면 아래 그림 10과 같이 Raw Data만 표시된다.

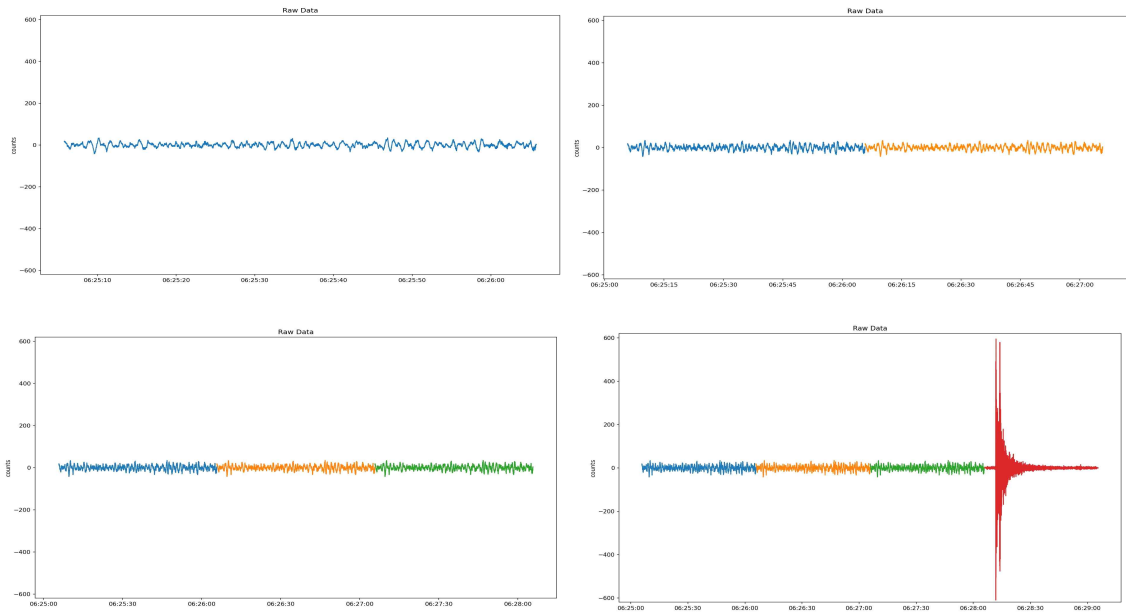


그림 10) 실시간 예측 결과1

그림 10의 우측 하단의 그래프를 보면 4번째로 입력된 데이터에 지진이 발생함을 알 수 있다. 모델이 각 데이터를 P파와 S파가 각각 도착하는 시간을 반환하는 함수를 실행하는 동안은 그림10의 4번째(우측 하단) 그래프처럼 표시된다. 해당 함수의 실행이 완료되면, 아래 그림11과 같이 검은 점선으로 P파와 S파의 도착 시간이 표시된다.

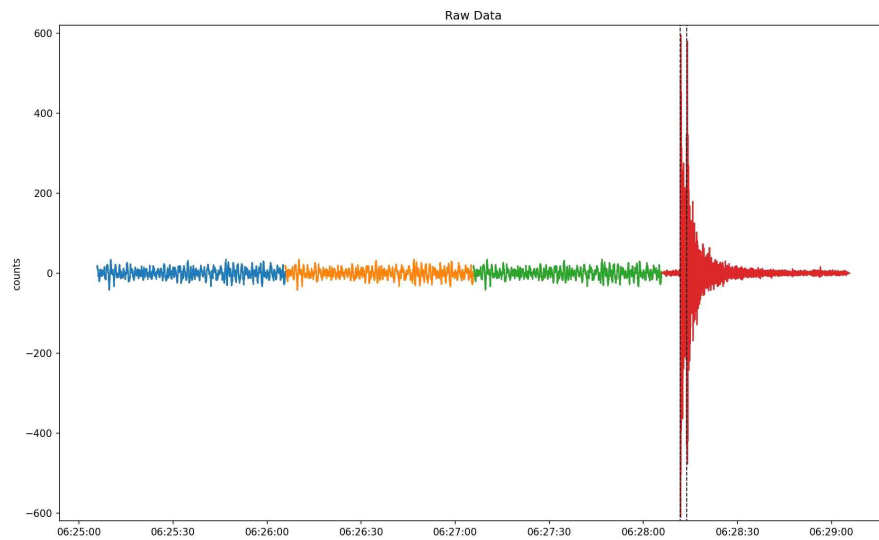


그림 11) 실시간 예측 결과2

통상적으로 그러하듯, 먼저 도착한 점선이 P파이고 이후에 표시된 점선이 S파이다. 1분 단위의 데이터를 입력하면 실시간으로 예측 함수를 수행하고, 이를 표시하는 기능이다.

4. 연구 결과 분석 및 평가

4.1 모델 학습 결과

해당 연구에서는 전체 120만 개의 STEAD 데이터 중 10만 개의 노이즈와 40만 개의 지진 데이터, 도합 50만 개의 데이터를 사용해 모델 학습을 진행하였다. 또한 각 모델을 학습할 때 epoch은 모두 10으로 설정하였다.

4.1.1 파라미터

Section	EQT	LEQ	FEQ3
Encoder	34,672	1,289	1,289
ResNet (Deeper Bottleneck)	160,128	3,712	1,888
LSTM(GRU) & Transformer	134,820	30,644	24,772
Decoder	43,875	4,131	4,131
Total	373,495	39,776	32,080

표 1) 파라미터 수 비교1

표 1은 기존 모델들과 본 연구에서 제시하는 최종 모델의 파라미터 수를 비교한 결과이다. ResNet(Deeper Bottleneck)의 블록 수를 감소시키고 LSTM을 GRU로 변경함으로써 파라미터 수가 감소하였다.

Section (cnn_block,lstm(gru)_ block)	FEQ1	FEQ2	FEQ3
Deeper Bottleneck	3,712	1,888	1,888
LSTM(GRU) & Transformer	26,964	23,204	24,772
Total	36,676	25,092	26,660

표 2) 파라미터 수 비교2

표 2는 본 연구에서 사용된 FEQ 모델들의 파라미터 수를 비교한 결과이다. (파라미터 수의 변화가 없는 부분은 생략하였다.) Bi-LSTM을 Bi-GRU로, LSTM을 GRU로 변경한 FEQ1 모델은 LEQ와 파라미터 수의 차이가 적었다. 따라서 각 블록들의 수를 1/2로 감소시켜 학습한 모델인 FEQ2는 비교적 파라미터 수가 많이 감소했음을 확인할 수 있었다. FEQ3는 Bi-GRU대신 Bi-LSTM 모델을 사용하였다. FEQ2와 비교하였을 때 파라미터 수가 약간 증가하였으나 FEQ1 보다는 감소하였음을 알 수 있다.

4.1.2 추론 속도

각 모델의 추론 속도를 비교하기 위해 동일한 데이터를 예측하는 속도를 측정해보았다. 아래 그림 12는 서버에서 1분 길이의 지진 데이터를 추론하는데 걸린 시간을 비교한 그래프이다.




그림 12) 추론 속도 비교1

FEQ1은 LEQ 보다 속도가 줄어들긴 했으나, 0.46초로 차이가 작았다. 블록 수를 절반으로 줄인 FEQ2 모델은 1.9초로 가장 적은 시간이 소요되었다. FEQ3 모델은 1.91초로 FEQ2 모델과 거의 차이가 나지 않았음을 알 수 있다.




그림 13) 추론 속도 비교2

그림 13은 서버보다 비교적 느린 환경이라 할 수 있는 개인 노트북에서 실행 시켜본 결과이다. 그림 12와 비교하여 보았을 때 알 수 있듯, 실행 환경에 따라 차이가 날 수 있다. 그러나 추론 속도의 차이는 있으나 성능의 순위는 바뀌지 않는다.

4.1.3 모델 크기

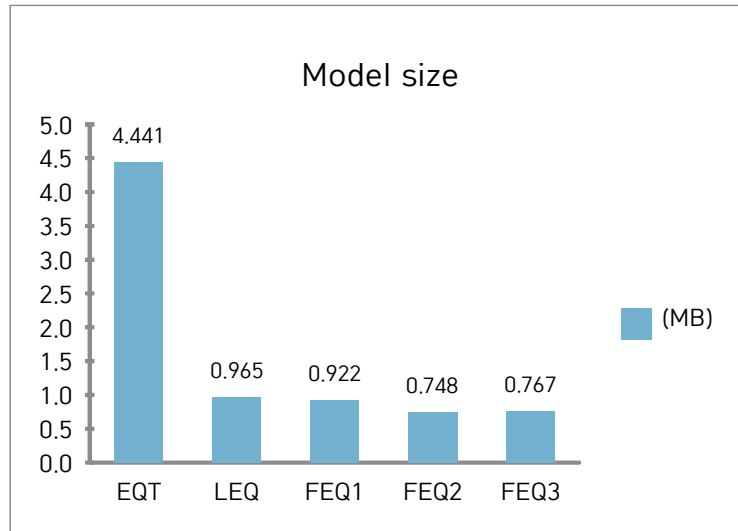


그림 14) 모델 크기 비교

그림 14는 각 모델들의 크기를 비교한 결과이다. 기존 EQT를 경량화한 LEQ는 약 0.965MB이다. FEQ1은 0.922로 LEQ와 큰 차이가 없다. FEQ2는 0.748로 가장 크기가 작았으며 LEQ와 비교해 약 22% 가량 감소하였다. FEQ3는 0.767로 FEQ2 보다는 약간 크지만 큰 차이는 보이지 않았다. 최종 모델로 제시한 FEQ3는 EQT에서는 82%, LEQ에서는 약 20% 크기가 감소하였다.

4.1.4 F1 Score

모델	Detection F1	P-phase F1	S-phase F1	Training Data Size
EQT	1.0	0.99	0.98	1.2M
LEQ	0.99	0.98	0.97	100K
FEQ3	0.99	0.99	0.98	500K

표 3) F1 Score 비교1

표3은 EQT와 LEQ에서 제시한 최종 모델과 FEQ3의 성능을 비교한 것이다. EQT 모델과 비교하면 전체 Detection에서 성능의 하락이 미세하게 있었지만, 학습 데이터 수의 차이를 고려하였을 때, 큰 문제는 아니라고 판단했다. 동일한 Dataset을 사용하여 각 모델들을 학습시켰을 때의 결과는 표4 와 같다.

모델	Detection F1	P-phase F1	S-phase F1
EQT	0.99	0.98	0.98
LEQ	0.99	0.99	0.97
FEQ1	0.99	0.98	0.97
FEQ2	0.99	0.97	0.95
FEQ3	0.99	0.99	0.98

표 4) F1 Score 비교2

표 4는 같은 Testset을 이용하여 각 모델들의 성능을 비교한 결과이다. 대부분 모델 간 큰 성능 차이는 없었지만, S파 감지 부분에서 차이를 볼 수 있다. EQT나 LEQ에 비해 Bi-GRU를 사용한 모델인 FEQ1,2는 미세한 성능의 하락을 보였다. 하지만 Bi-LSTM을 사용한 FEQ3는 EQT와 비슷한 수준이다.

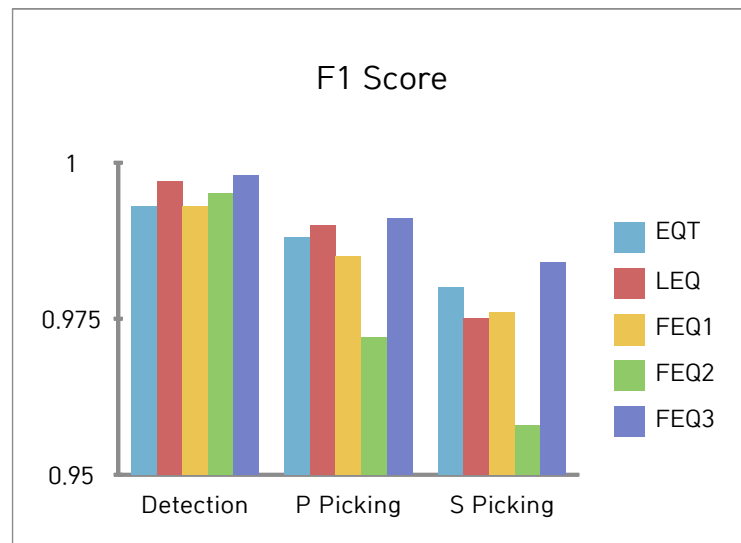


그림15) F1 Score 비교3

그림 15는 표 4의 수치를 소수점 아래 셋째 자리까지 반영한 결과를 그래프로 나타낸 것이다. 그래프에서 나타나듯, 최종 모델인 FEQ3가 높은 성능을 보인다.

4.1.5 False Negative

지진 감지에 있어서 지진 데이터를 비지진으로 판단하는 FN의 값은 가장 치명적이라고 판단했다. 본 연구에서 FN 값은 각 모델의 성능을 판단하는데 있어 중요한 지표로 사용되었다.

Section	FEQ1	FEQ2	FEQ3
Detection FN	131	256	31
P Picking FN	1,010	1,103	595
S Picking FN	1,517	3,087	1,132

표 5) FN 비교1

표 5는 FEQ 모델들의 FN을 비교한 결과이다. Bi-LSTM을 사용한 FEQ3는 Bi-GRU를 사용한 FEQ1,2에 비해 FN 수가 작음을 알 수 있다.

Section	EQT	LEQ	FEQ3
Detection FN	8	130	31
P Picking FN	626	673	595
S Picking FN	1,137	1,817	1,132

표 6) FN 비교2

표 6은 최종 모델로 제시하는 FEQ3와 기존 모델들의 FN을 비교한 결과이다. 전체 Detection 부분에서는 EQT 보다 FN 수치가 높았으나, P파와 S파 감지 부분에서는 오히려 FN의 수가 줄어들었음을 알 수 있다.

4.1.6 최종 모델 제시

본 연구에서는 파라미터 수, 모델 크기, 추론 속도 비교로 모델들의 활용 가능성을 살펴보았으며, F1 Score와 FN(False Negative)를 비교하여 모델들의 성능을 비교해 보았다. 해당 연구에서 개발한 세 가지 모델 중 최종적으로 제시하는 모델은 Bi-LSTM과 GRU 구조를 사용하는 FEQ3 모델이다.

초기 착수보고서에서 계획한 모델은 Bi-GRU 사용 모델인 FEQ1과 FEQ2였다. 하지만 블록 수가 많은 FEQ1 모델은 추론 속도와 모델 크기가 기존 LEQ와 거의 차이가 나지 않았다. 그래서 FEQ2는 블록 수를 줄여서 학습시켜 보았다. FEQ2는 추론 시간이 많이 감소하고 모델 크기도 많이 줄었지만, 성능 면에서 비교적 큰 하락이 있었다. 특히 4.1.5절 False Negative 비교에서 알 수 있듯, 지진 감지에 있어서 치명적이라 볼 수 있는 FN 값이 크다는 문제가 있었다. 이러한 문제를 해결하기 위해, FEQ2 보다 성능을 향상시키고 활용성 면에서 크게 차이가 없는 모델인 FEQ3를 개발했고, 이를 최종 모델로 선정하게 되었

다. FEQ3은 FEQ2 보다 모델 크기가 크고 추론 속도도 약간 느리지만 두 모델 간 차이는 적고, 기존 LEQ 보다는 활용성이 좋다. 그리고 성능 면에서 Detection과 S파 감지의 F1-Score는 EQT보다 약간 하락하였으나, P파 감지는 비슷한 수준을 유지하였다. 또한 LEQ보다는 P파 감지 부분에서 높은 성능을 보였다. 특히 FN을 검출하는 부분에 있어서 FEQ1과 FEQ2에 비해 성능이 많이 향상되었다. 이러한 결과를 토대로 FEQ3를 최종 모델로 제시하는 바이다.

5. 결론 및 향후 연구 방향

EQT는 약 4.5MB 정도의 모델 크기를 가지고 있었고, 많은 연산량을 필요로 하기 때문에 제한된 환경에서 빠르게 지진을 예측하는데 한계가 있었다. 이러한 문제를 해결하기 위해 EQT를 경량화한 LEQ를 기반으로 경량화와 추론 속도를 개선한 FEQ 모델을 개발하였다. CNN block과 Bi-LSTM block의 수를 1/2 줄였고 LSTM을 GRU로 변경하면서 학습하는데 사용되는 파라미터 수와 추론 시간을 감소시켰다. FEQ는 0.77MB로 EQT와 비교하여 모델 크기가 82% 감소되었고, 서버에서 소요된 추론 시간은 41%정도 감소되었다. 그렇게 모델 크기와 추론 속도를 개선한 FEQ 모델은 기존의 EQT와 성능 면에서 큰 차이를 보이지 않는다.

다만 FEQ는 최근 수요가 높은 메모리가 256KB 미만인 더 작은 장치에서 작동하기에는 더 큰 용량 축소가 필요하다는 한계가 있다. 또한 고성능의 서버에서는 1.91초로 빠른 예측이 가능하지만, 보편화 되어있는 개인 노트북과 같은 장치에서는 빠른 예측이 힘들다. 이러한 면에서 FEQ는 여전히 개선의 여지가 남아있다.

6. 개발 일정 및 역할 분담

6.1 개발 일정

5월		6월				7월				8월					9월			
3주	4주	1주	2주	3주	4주	1주	2주	3주	4주	1주	2주	3주	4주	5주	1주	2주	3주	4주
환경 구축 및 모델 스터디																		
		RNN 스터디, 모델 구조 및 데이터 분석																
						LSTM, Bi-LSTM을 GRU 모델로 변경, 중간 보고서 작성												
										모델 최적화 및 테스트, 실시간 예측 기능 구현								
															최종보고서 작성 및 발표 준비			

6.2 역할 분담

이름	역할 분담
정지호	-데이터 분석 및 실시간 예측 기능 구현
최지환	-모델 최적화 및 성능 개선
김주은	-모델 구조 분석 및 개선된 모델 구조 개발

7. 참고 문헌

[1] Mousavi, S. M., Ellsworth, W. L., Zhu, W., Chuang, L. Y., and Beroza, G. C. “Earthquake Transformer—An Attentive Deep—Learning Model for Simultaneous Earthquake Detection and Phase Picking” *Nat. Commun.* 11, 3952. 2020

[2] [Dataset] Mousavi, S. M., Sheng, Y., Zhu, W., and Beroza, G. C. “Stanford Earthquake Dataset (Stead): A Global Data Set of Seismic Signals for Ai.” *IEEE Access* 7, 179464–179476. 2019

[3]: Lim J, Jung S, JeGal C, Jung G, Yoo JH, Gahm JK and Song G “LEQNet: Light Earthquake Deep Neural Network for Earthquake Detection and Phase Picking.” *Front. Earth Sci.* 10:848237. 2022